LINEAR 9 - Data set: AIRQUALITY

INTRODUZIONE

Il data set contiene contiene 154 osservazioni con 6 variabili.

- 1. OZONO: concentrazioni di Ozono (parti per milione misurata a Roosevelt Island)
- 2. SOLAR.R: radiazione solare (misurata al Central Park)
- 3. WIND: velocità media del vento (misurata all'aeroporto LaGuardia)
- 4. TEMP: temperatura in F (misurata all'aeroporto LaGuardia)
- 5. MONTH: mese
- 6. DAY: giorno del mese

Analisi proposte:

- 1. Statistiche descrittive
- 2. Regressione lineare
- 3. Diagnostiche (QQ-plot, residui)

```
#-- R CODE
library(pander)
library(car)
library(olsrr)
library(systemfit)
library(het.test)
panderOptions('knitr.auto.asis', FALSE)
#-- White test function
white.test <- function(lmod,data=d){</pre>
  u2 <- lmod$residuals^2</pre>
  y <- fitted(lmod)
 Ru2 <- summary(lm(u2 \sim y + I(y^2)))$r.squared
 LM <- nrow(data)*Ru2
 p.value <- 1-pchisq(LM, 2)</pre>
  data.frame("Test statistic"=LM,"P value"=p.value)
#-- funzione per ottenere osservazioni outlier univariate
FIND_EXTREME_OBSERVARION <- function(x,sd_factor=2){</pre>
  which(x>mean(x)+sd_factor*sd(x) | x<mean(x)-sd_factor*sd(x))</pre>
}
#-- import dei dati
ABSOLUTE_PATH <- "C:\\Users\\sbarberis\\Dropbox\\MODELLI STATISTICI"
d <- read.csv(paste0(ABSOLUTE_PATH,"\\F. Esercizi(22) copia\\4.tutto(4)\\3.tutto\\airquality.txt"),sep=
#-- vettore di variabili numeriche presenti nei dati
VAR_NUMERIC <- c("Ozone", "Solar.R", "Wind", "Temp")</pre>
#-- print delle prime 6 righe del dataset
pander(head(d),big.mark=",")
```

id	Ozone	Solar.R	Wind	Temp	Month	Day
1	41	190	7	67	5	1
2	36	118	8	72	5	2
3	12	149	13	74	5	3
4	18	313	12	62	5	4
5	20	178	14	56	5	5
6	28	193	15	66	5	6

STATISTICHE DESCRITTIVE


#-- R CODE
pander(summary(d[,VAR_NUMERIC]),big.mark=",") #-- statistiche descrittive

Ozone	Solar.R	Wind	Temp
Min.: 1.00	Min.: 7.0	Min. : 2.00	Min. :56.00
1st Qu.: 20.00	1st Qu.:120.0	1st Qu.: 7.00	1st Qu.:72.00
Median: 33.00	Median $:201.0$	Median:10.00	Median: 79.00
Mean: 41.63	Mean : 185.8	Mean $:10.02$	Mean : 77.88
3rd Qu.: 60.00	3rd Qu.:256.0	3rd Qu.:12.00	3rd Qu.:85.00
Max. :168.00	Max. $:334.0$	Max. $:21.00$	Max. $:97.00$


pander(cor(d[,VAR_NUMERIC]),big.mark=",") #-- matrice di correlazione


	Ozone	Solar.R	Wind	Temp
Ozone	1	0.3608	-0.5403	0.6878
Solar.R	0.3608	1	-0.04474	0.2744
\mathbf{Wind}	-0.5403	-0.04474	1	-0.4555
\mathbf{Temp}	0.6878	0.2744	-0.4555	1

plot(d[,VAR_NUMERIC],pch=19,cex=.5) #-- scatter plot multivariato




```
par(mfrow=c(2,2))
for(i in VAR_NUMERIC){
  boxplot(d[,i],main=i,col="lightblue",ylab=i)
}
```





```
par(mfrow=c(2,2))
for(i in VAR_NUMERIC){
  hist(d[,i],main=i,col="lightblue",xlab=i,freq=F)
}
```



La variabile "ozono" che sarà scelta come variabile dipendente è maggiormente correlata con "temp", "solar" e "wind" in senso decrescente.

REGRESSIONE

Si effettua ora la regressione multipla di "ozono" su "temp", "solar" e "wind".

```
#-- R CODE
mod1 <- lm(Ozone ~ Wind + Temp + Solar.R,d)
pander(summary(mod1),big.mark=",")</pre>
```

	Estimate	Std. Error	t value	$\Pr(> t)$
(Intercept)	-66.66	17.67	-3.772	0.0002327
Wind	-2.569	0.4998	-5.139	8.518e-07
\mathbf{Temp}	1.548	0.197	7.858	7.186e-13
$\mathbf{Solar.R}$	0.07234	0.01886	3.835	0.0001845

Table 5: Fitting linear model: Ozone ~ Wind + Temp + Solar.R

Observations	Residual Std. Error	R^2	Adjusted \mathbb{R}^2
153	19.62	0.5797	0.5712

pander(anova(mod1),big.mark=",")

Table 6: Analysis of Variance Table

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Wind	1	39,823	39,823	103.5	8.711e-19
${f Temp}$	1	$33,\!588$	33,588	87.28	1.282e-16
$\mathbf{Solar.R}$	1	5,661	5,661	14.71	0.0001845
Residuals	149	$57,\!338$	384.8	NA	NA

pander(white.test(mod1),big.mark=",")

Test.statistic	P.value
6.915	0.03151

pander(dwtest(mod1),big.mark=",")

Table 8: Durbin-Watson test: mod1

Test statistic	P value	Alternative hypothesis
1.7	0.02467 *	true autocorrelation is greater than 0

Sia il modello che le singole variabili risultano significative e l' \mathbb{R}^2 è sufficientemente elevato (0.58). Si passa ora all'esame della collinearità.

Sia l'indice di tolleranza che il Vif escludono la collinearità tuttavia il condition index vicino alla soglia (28.56) e la proporzione di varianza di "temp" per il 4° autovalore indicano una qualche anomalia.


Eigenvalue	Condition Index	intercept	Wind	Temp	Solar.R
3.757	1	0.0005601	0.005749	0.0007252	0.01056
0.1592	4.857	0.00118	0.2021	1.273 e-05	0.6459
0.07882	6.905	0.0157	0.4244	0.04309	0.3135
0.004606	28.56	0.9826	0.3677	0.9562	0.02996

pander(ols_vif_tol(mod1),big.mark=",")


Variables	Tolerance	VIF
Wind	0.7856	1.273
Temp	0.7279	1.374
Solar.R	0.9166	1.091

Passiamo ora all'esame degli outlier inziando dall'analisi dei grafici inerenti i residui.


```
#-- R CODE
plot(mod1,which=1,pch=19)
```




plot(mod1, which=2, pch=19)




plot(mod1,which=3,pch=19)



plot(mod1,which=4,pch=19)
abline(h=2*4/nrow(d),col=2,lwd=3,lty=2)



plot(mod1,which=5,pch=19)





```
#-- R CODE
par(mfrow=c(2,2))
plot(d$Temp,resid(mod1),pch=19,xlab="Temp",ylab="Residual")
abline(h=0,lwd=3,lty=2,col=2)


plot(d$Wind,resid(mod1),pch=19,xlab="Wind",ylab="Residual")
abline(h=0,lwd=3,lty=2,col=2)


plot(d$Solar.R,resid(mod1),pch=19,xlab="Solar",ylab="Residual")
abline(h=0,lwd=3,lty=2,col=2)

plot(1:nrow(d),rstudent(mod1),pch=19,xlab="Observation Index",ylab="Residual Studentized",type="h")
abline(h=2,lwd=3,lty=2,col=2)
abline(h=-2,lwd=3,lty=2,col=2)
```











> >

#-- R CODE

plot(covratio(mod1),pch=19,ylab="Covratio")
abline(h=1-3*7/nrow(d),lwd=3,col=2,lty=2)
abline(h=1+3*7/nrow(d),lwd=3,col=2,lty=2)





```
plot(dffits(mod1),pch=19,ylab="DFFITS",type="h")
abline(h=2*sqrt(4/nrow(d)),lwd=3,col=2,lty=2)
abline(h=-2*sqrt(4/nrow(d)),lwd=3,col=2,lty=2)
```




dfbetaPlots(mod1,pch=19,main="DFBETA")

DFBETA







Considerazioni generali:

- 1. Dal QQ-Plot e dagli altri grafici si notano anomalie alle estremità della distribuzione.
- 2. Dall'analisi del leverage plot si notano alcuni valori al di fuori dalla banda che identifica i valori critici data da 2 volte il numero dei regressori diviso n.
- 3. Dall'analisi dei residui studentizzati si osservano alcuni valori al di fuori dalla banda che identifica i valori critici.
- 4. Dall'analisi dei DFITTS (pe misurare l'influenza delle singole osservazioni sul coefficiente di regressione e sulla loro varianza quando è rimosso dal processo di stima) anche in questo caso vi sono valori oltre la soglia di tolleranza.
- 5. La presenza di valori anomali è confermata anche dai DFBETA

Eliminiamo quindi le osservazioni: 30, 62, 86, 99, 101, 117, 9 e 48.

```
#-- R CODE

d1 <- d[-c(30, 62, 86, 99, 101, 117, 9, 48),]

mod1 <- lm(Ozone ~ Wind + Temp + Solar.R,d1)

pander(summary(mod1),big.mark=",")
```

	Estimate	Std. Error	t value	$\Pr(> t)$
(Intercept)	-77.91	13.48	-5.781	4.571e-08
Wind	-1.773	0.4096	-4.328	2.831e-05
Temp	1.591	0.1487	10.7	6.333e-20

	Estimate	Std. Error	t value	$\Pr(> t)$
Solar.R	0.05667	0.01439	3.937	0.0001293

Table 12: Fitting linear model: Ozone ~ Wind + Temp + Solar.R

Observations	Residual Std. Error	R^2	Adjusted \mathbb{R}^2
145	14.65	0.6564	0.6491

pander(anova(mod1),big.mark=",")

Table 13: Analysis of Variance Table

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Wind	1	22,058	22,058	102.7	1.797e-18
\mathbf{Temp}	1	$32,\!457$	32,457	151.1	4.6e-24
$\mathbf{Solar.R}$	1	3,328	3,328	15.5	0.0001293
Residuals	141	$30,\!279$	214.7	NA	NA

pander(white.test(mod1),big.mark=",")

Test.statistic	P.value
21.01	2.741e-05


pander(dwtest(mod1),big.mark=",")

Table 15: Durbin-Watson test: mod1


Test statistic	P value	Alternative hypothesis
1.585	0.004512 * *	true autocorrelation is greater than 0

Migliora l' \mathbb{R}^2 che sale a 0.65. Si verifica ora su questo modello con 145 osservazioni la normalità dei residui analizzando la distribuzione dei residui e il loro box-plot.


#-- R CODE
plot(mod1,which=1,pch=19)




plot(mod1, which=2, pch=19)




plot(mod1, which=3, pch=19)



plot(mod1,which=4,pch=19)
abline(h=2*4/nrow(d1),col=2,lwd=3,lty=2)



plot(mod1,which=5,pch=19)





```
#-- R CODE
par(mfrow=c(2,2))
plot(d1$Temp,resid(mod1),pch=19,xlab="Temp",ylab="Residual")
abline(h=0,lwd=3,lty=2,col=2)


plot(d1$Wind,resid(mod1),pch=19,xlab="Wind",ylab="Residual")
abline(h=0,lwd=3,lty=2,col=2)


plot(d1$Solar.R,resid(mod1),pch=19,xlab="Solar",ylab="Residual")
abline(h=0,lwd=3,lty=2,col=2)

plot(1:nrow(d1),rstudent(mod1),pch=19,xlab="Observation Index",ylab="Residual Studentized",type="h")
abline(h=2,lwd=3,lty=2,col=2)
abline(h=-2,lwd=3,lty=2,col=2)
```











> >

#-- R CODE

plot(covratio(mod1),pch=19,ylab="Covratio")
abline(h=1-3*7/nrow(d1),lwd=3,col=2,lty=2)
abline(h=1+3*7/nrow(d1),lwd=3,col=2,lty=2)



hist(resid(mod1),col="lightblue",freq=F,xlab="Resid",main="")
lines(density(resid(mod1)),col=2,lwd=2)



pander(shapiro.test(resid(mod1)))

Table 16: Shapiro-Wilk normality test: resid(mod1)

Test statistic	P value
0.9805	0.03651 *

pander(ks.test(resid(mod1), "pnorm"))

Table 17: One-sample Kolmogorov-Smirnov test: resid(mod1)

Test statistic	P value	Alternative hypothesis
0.4949	0 * * *	two-sided

Si può quindi concludere che la distribuzione si discosta dalla normalità ma in modo non rilevante e quindi si può accettare l'ipotesi di normalità se non si ritiene di non voler essere troppo stringenti nelle condizioni per accettare la normalità.

L'analisi residui-valori predetti e quella dei residui inerenti regressioni uni variate rispetto ai singoli regressori mostrano residui che si collocano in modo non regolare intorno allo 0, non certo secondo una forma rettangolare. Per le osservazioni estreme i residui sembrano molto discosti dal valore zero a differenza che in centro della distribuzione a segnalare la probabile non sfericità degli errori.

Il p-value del p-value del test di Dubin Whatson ci porta a rifiutare l'ipotesi nulla di incorrelazione fra i

residui.

```
#-- R CODE
pander(white.test(mod1),big.mark=",")
```

Test.statistic	P.value
21.01	2.741e-05

pander(dwtest(mod1),big.mark=",")

Table 19: Durbin-Watson test: mod1

Test statistic	P value	Alternative hypothesis	
1.585	0.004512 * *	true autocorrelation is greater than 0	